

T2_NLP

March 8, 2025

Matias Herklotz (PECE/USP) – 2025

1 Tarefa: Linguística Forense

Seu grupo de especialistas em PLN foi chamado para periciar um texto de autor incógnito. Há três elementos suspeitos de ser o autor da obra. Todos negam veementemente a autoria. São eles:

- Machado de Assis, autor de “Dom Casmurro”
- José de Alencar, autor de “O Guarani”
- Joaquim Nabuco, autor de “O Abolicionismo”

Você tem à disposição esses livros para comparar com o livro apócrifo.

Em suas análises, use alguns dos recursos comuns da Linguística Forense:

- Análise das divisões de período (para simplificar: tamanho das sentenças);
- Comparação das colocações adverbiais, em especial os modais (etiqueta de dependência: “advmmod”) e as conjunções subordinativas (“que” e “se”; etiqueta: “sconj”).

Ao final, responda: quem é o autor do livro apócrifo?

```
[86]: import nltk
import spacy
import pandas as pd
from nltk.tokenize import sent_tokenize, word_tokenize
from matplotlib import pyplot as plt
nltk.download('punkt_tab')

nlp = spacy.load('pt_core_news_sm')
```

```
[nltk_data] Downloading package punkt_tab to
[nltk_data] C:\Users\mathe\AppData\Roaming\nltk_data...
[nltk_data] Package punkt_tab is already up-to-date!
```

```
[ ]: def ler(nome_arquivo) -> str:
    with open(nome_arquivo, 'r', encoding='utf-8') as arquivo:
        return arquivo.read()

def tokenizar(txt: str) -> list:
```

```

    return word_tokenize(txt, language='portuguese')

def tokenizar_sentencas(txt: str) -> list:
    txt = txt.replace('\n', ' ')
    return sent_tokenize(txt, language='portuguese')

def limpar(lista: list) -> list:
    return [i.lower() for i in lista if i.isalpha()]

def contar_pos(txt: str) -> dict:
    doc = nlp(txt)
    return {
        "N_Advs": sum(1 for t in doc if t.pos_ == "ADV"),
        "N_Adjs": sum(1 for t in doc if t.pos_ == "ADJ"),
        "N_Verbs": sum(1 for t in doc if t.pos_ == "VERB"),
        "N_CConj": sum(1 for t in doc if t.pos_ == "CCONJ"),
        "N_SConj": sum(1 for t in doc if t.pos_ == "SCONJ"),
        "N_Pron": sum(1 for t in doc if t.pos_ == "PRON"),
    }

def textos_df(arq: str) -> pd.DataFrame:
    txt = ler(arq)
    sentencas = tokenizar_sentencas(txt)
    df_obra = pd.DataFrame({'Sentencas': sentencas})
    df_obra['TamSentencas'] = df_obra['Sentencas'].str.len()
    # df_obra['ListaPalavras'] = df_obra['Sentencas'].apply(lambda x:
    ↪tokenizar(x))
    df_obra['NumPalavras'] = df_obra['Sentencas'].apply(lambda x:
    ↪len(tokenizar(x)))

    pos_counts_df = df_obra["Sentencas"].apply(contar_pos).apply(pd.Series).
    ↪fillna(0)

    df = pd.concat([df_obra, pos_counts_df], axis=1)

    return df

```

```

[153]: df_g = textos_df('Guarani.txt')
df_g['Autor'] = 'José de Alencar'

df_dc = textos_df('DomCasmurro.txt')
df_dc['Autor'] = 'Machado de Assis'

```

```
df_a = textos_df('Abolicionismo.txt')
df_a['Autor'] = 'Joaquim Nabuco'

df_d = textos_df('LivroApócrifo.txt')
df_d['Autor'] = '???'
```

```
[154]: df = pd.concat([df_g, df_dc, df_a, df_d], ignore_index=True)
df.head()
```

```
[154]:
```

		Sentencas	TamSentencas	\
0	0	Guarani, de José de Alencar Fonte: ALENCAR, ...	54	
1		0 guarani.	10	
2		20a ed., São Paulo: Ática, 1996 (Bom Livro).	44	
3		Texto proveniente de: A Biblioteca Virtual do ...	196	
4		Este material pode ser redistribuído livrement...	120	

	NumPalavras	N_Advs	N_Adjs	N_Verbs	N_CConj	N_SConj	N_Pron	\
0	14	0	0	0	0	0	0	
1	3	0	1	0	0	0	0	
2	14	0	1	0	0	0	0	
3	32	1	2	0	0	0	0	
4	21	3	0	4	1	3	0	

	Autor
0	José de Alencar
1	José de Alencar
2	José de Alencar
3	José de Alencar
4	José de Alencar

```
[156]: df_grouped = df.groupby("Autor").sum()
df_grouped = df_grouped.drop(['Sentencas'], axis=1)
df_grouped.head()
```

```
[156]:
```

	TamSentencas	NumPalavras	N_Advs	N_Adjs	N_Verbs	N_CConj	\
Autor							
???	215974	43107	1467	2060	5140	1216	
Joaquim Nabuco	387521	72724	3769	4376	7336	2494	
José de Alencar	617918	124634	5551	5504	17652	4268	
Machado de Assis	395492	83161	5330	3680	11562	3242	

	N_SConj	N_Pron
Autor		
???	1090	1762
Joaquim Nabuco	2103	4038
José de Alencar	3537	7588
Machado de Assis	3101	4727

```
[ ]: df_grouped["Advérbios"] = (df_grouped["N_Advs"] / df_grouped["NumPalavras"]) * 100
df_grouped["Adjetivos"] = (df_grouped["N_Adjs"] / df_grouped["NumPalavras"]) * 100
df_grouped["Verbos"] = (df_grouped["N_Verbs"] / df_grouped["NumPalavras"]) * 100
df_grouped["Conjunções Coordenativas"] = (df_grouped["N_CConj"] / df_grouped["NumPalavras"]) * 100
df_grouped["Conjunções Subordinativas"] = (df_grouped["N_SConj"] / df_grouped["NumPalavras"]) * 100
df_grouped["Pronomes"] = (df_grouped["N_Pron"] / df_grouped["NumPalavras"]) * 100
```

```
[158]: df_grouped.head()
```

```
[158]:
```

	TamSentencas	NumPalavras	N_Advs	N_Adjs	N_Verbs	N_CConj	\
Autor							
???	215974	43107	1467	2060	5140	1216	
Joaquim Nabuco	387521	72724	3769	4376	7336	2494	
José de Alencar	617918	124634	5551	5504	17652	4268	
Machado de Assis	395492	83161	5330	3680	11562	3242	

	N_SConj	N_Pron	Advérbios	Adjetivos	Verbos	\
Autor						
???	1090	1762	3.403160	4.778806	11.923817	
Joaquim Nabuco	2103	4038	5.182608	6.017271	10.087454	
José de Alencar	3537	7588	4.453841	4.416130	14.163069	
Machado de Assis	3101	4727	6.409254	4.425151	13.903152	

	Conjunções Coordenativas	Conjunções Subordinativas	\
Autor			
???	2.820888	2.528592	
Joaquim Nabuco	3.429404	2.891755	
José de Alencar	3.424427	2.837909	
Machado de Assis	3.898462	3.728911	

	Pronomes
Autor	
???	4.087503
Joaquim Nabuco	5.552500
José de Alencar	6.088226
Machado de Assis	5.684155

```
[160]: cols_proporcao = [
    "Advérbios",
    "Adjetivos",
    "Verbos",
    "Pronomes",
```

```

"Conjunções Coordenativas",
"Conjunções Subordinativas",
"Interjeições"
]

import matplotlib.pyplot as plt

fig, axes = plt.subplots(nrows=2, ncols=3, figsize=(16, 8))
fig.suptitle("Proporção de Tipos de Palavras por Autor", fontsize=16)

axes = axes.flatten()


for ax, col in zip(axes, cols_proporcao):
    df_grouped[col].plot(kind="bar", ax=ax, width=0.8)
    ax.set_title(col)
    ax.set_xlabel("Autor")
    ax.set_ylabel("Proporção (%)")
    ax.tick_params(axis='x', rotation=45)

    for p, autor in zip(ax.patches, df_grouped.index):
        altura = p.get_height()
        ax.text(p.get_x() + p.get_width() / 2, altura, f"{altura:.2f}%",
        ha='center', va='bottom', fontsize=9)

    if autor == "???":
        ax.axhline(y=altura, color='red', linestyle='dashed', linewidth=1)

plt.tight_layout(rect=[0, 0, 1, 1])
plt.show()

```



1.1 Analise

- Advérbios: texto esta mais alinhado com Alencar
- Adjetivos: texto esta menos alinhado com Nabuco
- Verbos: Inconclusivo
- Pronomes: Parece estar menos alinhado com Alencar, mas tambem distante do restante
- Conjuncoes: Ambas as conjuncoes mostram que Machado esta mais distante.

Por exclusao a analise mostra uma maior proximidade com Alencar

```
[162]: df_sen = df[['Autor', 'TamSentencas']].groupby("Autor").mean()
df_sen.head()
```

```
[162]:
```

	TamSentencas
Autor	
???	111.441692
Joaquim Nabuco	210.380565
José de Alencar	106.943233
Machado de Assis	92.773164


```
[139]: ax = df_sen.plot(kind="bar", figsize=(12, 6), width=0.8)

plt.title("Média de Tamanho das Sentenças por Autor")
plt.xlabel("Autor")
plt.ylabel("Média")
plt.xticks(rotation=0)

for p, autor in zip(ax.patches, df_sen.index):
    altura = p.get_height()
    plt.text(p.get_x() + p.get_width() / 2, altura, f"{altura:.2f}",
             ha='center', va='bottom', fontsize=10)

    if autor == "???":
        ax.axhline(y=altura, color='red', linestyle='dashed', linewidth=1)

plt.show()
```



1.2 Analise Final

Ao analisar a proporção de tipos de palavra por autor podemos ver que Machado de Assis é o mais deslocado dos 3, principalmente quando observamos os Advérbios e as conjunções.

Ficamos entre Alencar e Nabuco, com uma tendencia maior ao Alencar.

Porém ao ver a media de palavras por sentença, podemos ver que Joaquim Nabuco é praticamente excluído, restando apenas o Alencar.

Podemos concluir então que Alencar é o Autor da obra Livro Apócrifo.